TUGAS MANDIRI 1 PRAKTIKUM

STA1231 ANALISIS REGRESI

Nama : Muhammad Khayruhanif

NIM : M0401241058

Paralel : K2/P2

Kode Program : GitHub

Muatan :

- Data
- Eksplorasi Data
- Model Analisis Regresi Sederhana
- Signifikansi Simultan (F)
- Standar Error Parameter Regresi
- Signifikansi Parameter (Nilai-t)
- Selang Kepercayaan Parameter
- Selang Kepercayaan Bagi Nilai Rataan/Nilai Harapan Amatan
- Selang kepercayaan Bagi Individu Amatan
- Koefisien Determinasi
- Kesimpulan

---

1. Data

No.	YearsOfSchooling (X)	HDI (Y)	No.	YearsOfSchooling (X)	HDI (Y)
1	18.99603	0.945	16	16.74228	0.942
2	16.45468	0.888	17	16.91242	0.869
3	15.79271	0.78	18	19.18488	0.947
4	15.88826	0.935	19	18.85059	0.964
5	16.28428	0.927	20	14.59442	0.704
6	11.18842	0.602	21	18.58485	0.953
7	14.94685	0.873	22	15.96786	0.902
8	16.7142	0.905	23	13.04355	0.751
9	15.4694	0.867	24	17.47717	0.926
10	15.923	0.93	25	13.32801	0.772
11	16.2156	0.908	26	14.46811	0.783
12	12.46087	0.737	27	14.05288	0.84
13	16.7935	0.911	28	17.30922	0.955

14	12.519769	0.81	29	14.90782	0.921
15	14.93416	0.921	30	18.70401	0.959

Data yang digunakan untuk analisis regresi sederhana ini diantaranya Rataan Lama Sekolah (YearsOfSchooling) dalam satuan tahun sebagai data independen dan data IPM (HDI) atau Indeks Pembangunan Manusia. Data diambil dari website ourworldindata.org dalam tahun 2022. Tugas ini menggunakan 30 data acak diambil dari 64 data yang tersedia.

2. Eksplorasi Data

Analisis 5 serangkai data Rataan Lama Sekolah (X) dan IPM (Y):

```{r}
cat("Eksplorasi data X:\n")
summary(data$X)

cat("\n")

cat("Eksplorasi data Y:\n")
summary(data$Y)
```

```
Eksplorasi data X:
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
  11.19   14.67   15.95   15.82   16.88   19.18 

Eksplorasi data Y:
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
 0.6020  0.8175  0.9065  0.8709  0.9337  0.9640 
```

Kedua data menunjukkan nilai median dan mean yang hampir sama sehingga dapat dikatakan data membentuk kurva distribusi normal.

Boxplot dari data Rataan Lama Sekolah dan IPM:

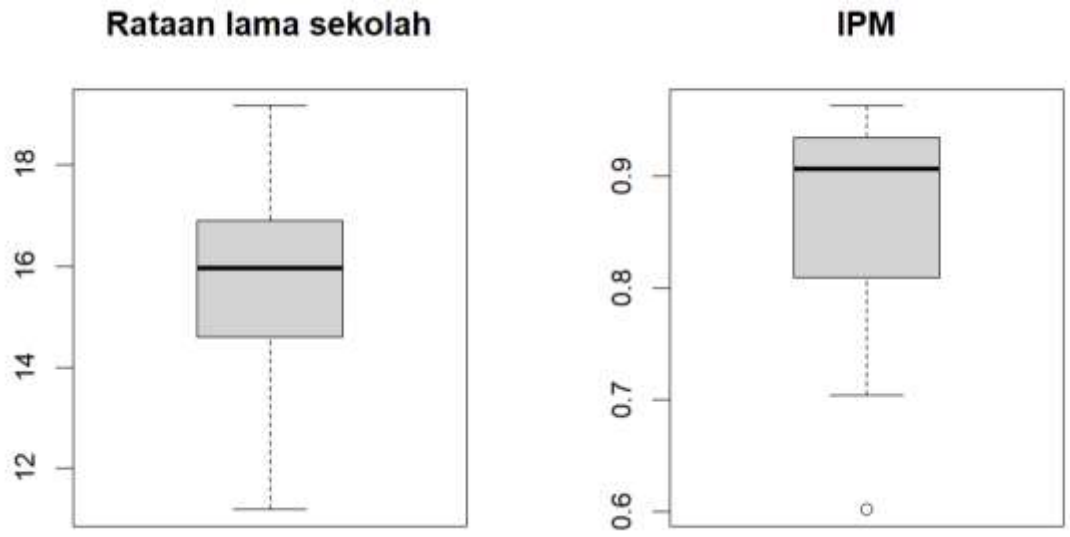

Scatter plot:

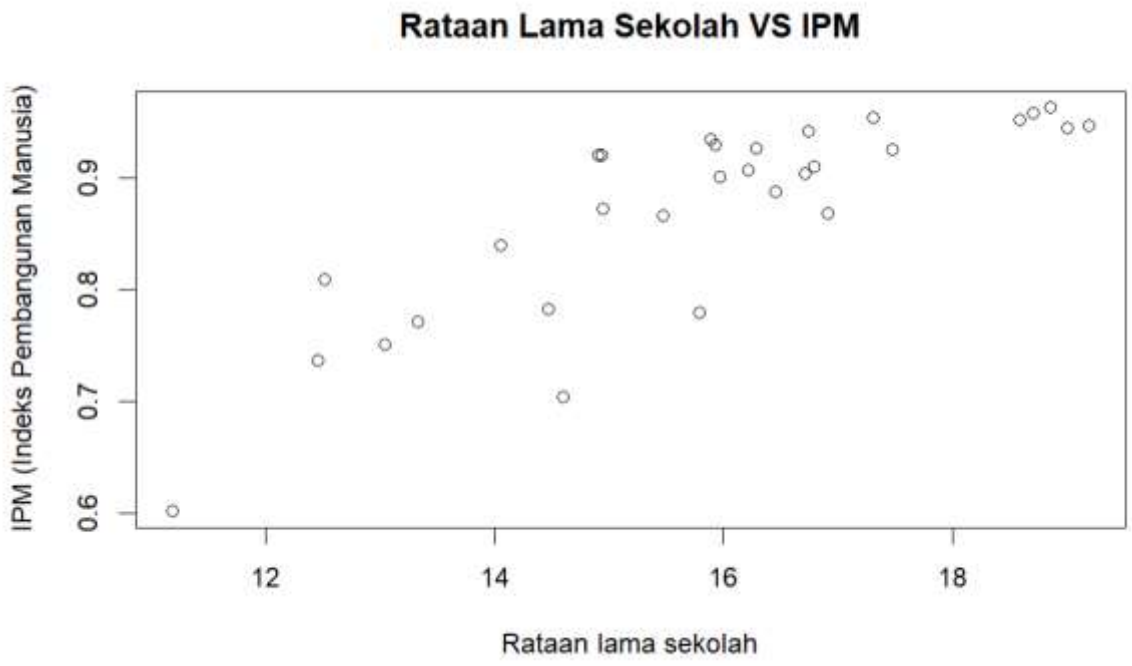

3. **Model Analisis Regresi Sederhana**

$$\widehat{y_i} = \widehat{\beta_0} + \widehat{\beta_1} x_i, i = 1,2,3, \dots, n$$

- $\widehat{y_i}$: Peubah acak analisis regresi sederhana
- β_0: Intersep
- β_1: Kemiringan garis

```{r}
n <- nrow(data)

b1 <- (sum(x*y)-sum(x)*sum(y)/n)/(sum(x^2)-(sum(x)^2/n))
b0 <- mean(y)-b1*mean(x)

cat("Koefisien b1:", b1, "\n")
```

```
Koefisien b1: 0.03617844
```

$$S_{XY} = \sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y})$$

$S_{XY} = (18.99603 - 15.82365997)(0.945 - 0.871) + (16.45468 - 15.82365997)(0.888 - 0.871) + (15.79271 - 15.82365997)(0.780 - 0.871) + \cdots + (18.70401 - 15.82365997)(0.959 - 0.871) = 4.436$

$$S_{XX} = \sum_{\mathrm{i}=1}^{\mathrm{n}} (\mathrm{X_i} - \overline{\mathrm{X}})(\mathrm{X_i} - \overline{\mathrm{X}})$$

$S_{XX} = (18.99603 - 15.82365997)(18.99603 - 15.82365997) + (16.45468 - 15.82365997)(16.45468 - 15.82365997) + (15.79271 - 15.82365997)(15.79271 - 15.82365997) + \cdots + (18.70401 - 15.82365997)(18.70401 - 15.82365997) = 122.6$

$$\beta_1 = \frac{S_{XY}}{S_{XX}} = \frac{4.436}{122.6} = 0.036$$

- β_1: Kemiringan garis
- S_{XX}: Jumlah kuadrat penyimpangan X
- S_{XY}: Jumlah produk penyimpangan X dan Y

Setiap kenaikan 1 satuan Rataan Lama Sekolah (X), maka diprediksi nilai IPM (Y) akan meningkat sebesar 0,036 unit.

```{r}
cat("Koefisien b0:", b0, "\n")
```

```
Koefisien b0: 0.2984246
```

$$\beta_0 = \bar{Y} - \beta_1 \bar{X}$$

- β_0: Intersep
- $\bar{Y}$: Rataan peubah dependen
- β_1: Kemiringan garis
- $\bar{X}$: Rataan peubah independen

$$\beta_0 = 0.871 - (0.036)(15.82365997) = 0.298$$

Ketika Rataan Lama Sekolah bernilai 0, maka nilai IPM diprediksi sebesar 0,298.

Model analisis regresi sederhana:

$$\hat{y}_i = 0.298 + 0.036x_i, i = 1,2,3, \dots, n$$

```
### Menggunakan Fungsi lm()
Memperoleh secara langsung nilai-nilai pada pemodelan regresi dari data yang kita miliki.
hanya denggan mengeluarkan summary dan anova dari model yang terbentuk maka dapat
diperoleh nilai parameter, signifikansinya, standar eror, koefisien determinasi, hingga
ukuran keragamannya
```{r}
model <- lm(Y~X, data = data)
summary(model)
```
```
Call:
lm(formula = Y ~ X, data = data)

Residuals:
     Min       1Q   Median       3Q      Max 
-0.12243 -0.01894 -0.00142  0.03366  0.08323 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 0.298425   0.073665   4.051 0.000366 ***
X           0.036178   0.004618   7.834 1.56e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.05114 on 28 degrees of freedom
Multiple R-squared:  0.6867,	Adjusted R-squared:  0.6755 
F-statistic: 61.38 on 1 and 28 DF,  p-value: 1.558e-08
```

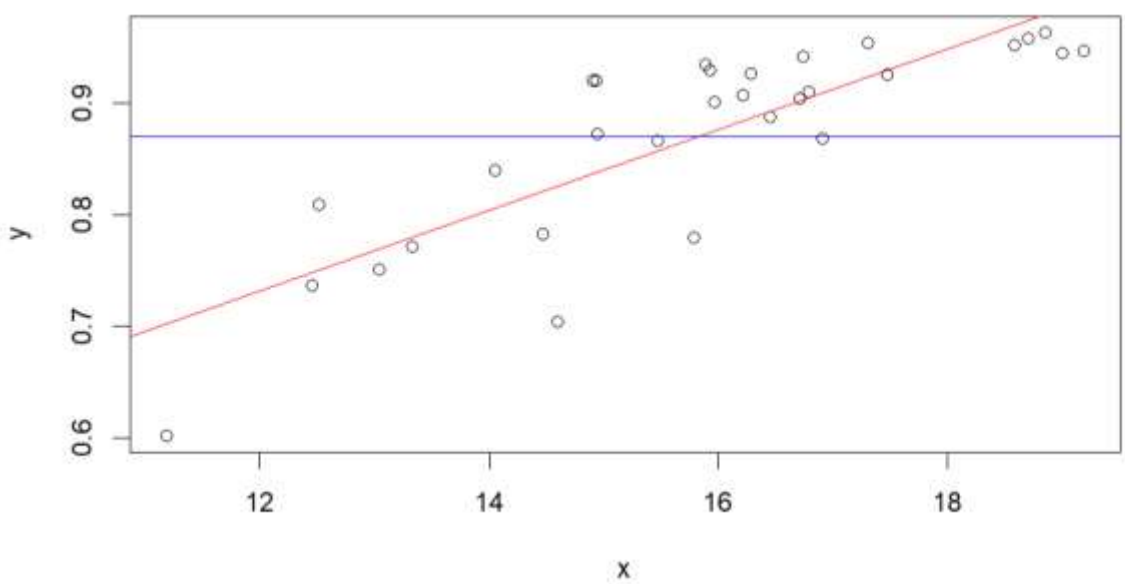

4. **Signifikansi Simultan (F)**

Hipotesis:

H_0: Model tidak layak (data Rataan Lama Sekolah tidak mampu menjelaskan keragaman data IPM)
```

H_1: Model Layak (data Rataan Lama Sekolah mampu menjelaskan keragaman data IPM)

Sumber Keragaman	Derajat Bebas (db)	Jumlah Kuadrat (JK)	Kuadrat Tengah (KT)
Regresi	1	$JKR = \sum(\hat{y}_i - \bar{y})^2$	$KTR = \frac{JKR}{1}$
Sisaan	$n - 2$	$JKG = \sum(y_i - \hat{y}_i)^2$	$KTG = \frac{JKG}{n-2}$
Total	$n - 1$	$JKT = \sum(y_i - \bar{y})^2$	

```
{r}
ANOVA.MODEL <- aov(model)
ANOVA.MODEL
```

```
Call:
   aov(formula = model)

Terms:
                        X  Residuals
Sum of Squares  0.16049947 0.07321723
Deg. of Freedom         1         28

Residual standard error: 0.0511361
Estimated effects may be unbalanced
```

Sumber Keragaman	Derajat Bebas (db)	Jumlah Kuadrat (JK)	Kuadrat Tengah (KT)
Regresi	1	0.1605	0.1605
Sisaan	28	0.0732	0.0026
Total	29	0.2337	

$$f_{hitung} = \frac{KTR}{KTG} = \frac{0.1605}{0.0026} = 61.379$$

$$f_{tabel} = f_{\{0.05;1;28)} = 4.20$$

Karena F-hitung (61.379) > F-tabel (4.20), maka model regresi linear dianggap layak dan bisa digunakan.

5. Standar Error Parameter Regresi

```
### Standar Error Parameter Regresi
Menunjukkan seberapa besar ketidakpastian dalam estimasi koefisien
```{r}
galat <- y-(b0+b1*x)
ragam_galat <- sum(galat^2)/(n-2)

se_b0 <- sqrt(ragam_galat*(1/n+mean(x)^2/sum((x-mean(x))^2)))
se_b1 <- sqrt(ragam_galat/sum((x-mean(x))^2))

cat("Standar error b0:", se_b0, "\n")
```
```
Standar error b0: 0.07366545
```

Simpangan baku intersep:

$$S_{b_0} = \sqrt{S_e^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}}\right)}, S_e^2 = \frac{JKG}{n-2}$$

Hasil:

$$S_{b_0} = \sqrt{\frac{0.073}{30-2}\left(\frac{1}{30} + \frac{(250.388)^2}{122.6}\right)} = 0.07367$$

```
```{r}
cat("Standar error b1:", se_b1, "\n")
```
```
Standar error b1: 0.004617859
```

Simpangan baku kemiringan regresi:

$$S_{b_1} = \sqrt{\frac{S_e^2}{S_{XX}}}, S_e^2 = \frac{JKG}{n-2}$$

Hasil:

$$S_{b_1} = \sqrt{\frac{\left(\frac{0.073}{30-2}\right)}{122.6}} = 0.00462$$

6. **Signifikansi Parameter (nilai-t)**

Uji hipotesis parameter regresi β_0

Hipotesis:

H_0: $\beta_0 = 0$ (Nilai IPM saat Rataan Lama Sekolah nol adalah sama dengan nol)

H_1: $\beta_0 \neq 0$ (Nilai IPM saat Rataan Lama Sekolah nol tidak sama dengan nol)

```
### Signifikansi Parameter (nilai-t)
Menunjukkan tingkat signifikansi secara parsial dari setiap koefisien peubah berdasarkan
nilai t dan probabilitas nilai p
```{r}
t_b0 <- b0/se_b0
t_b1 <- b1/se_b1
p_b0 <- 2*pt(-abs(t_b0 ),df<-n-2)
p_b1 <- 2*pt(-abs(t_b1 ),df<-n-2)

cat("Nilai t pada b0 adalah", t_b0, "dengan nilai p sebesar", p_b0, "\n")
```
```
Nilai t pada b0 adalah 4.05108 dengan nilai p sebesar 0.0003663679
```

$$t_{b_0} = \frac{b_0}{S_{b_0}} = \frac{0.298}{0.07367} = 4.05108$$

Uji hipotesis parameter regresi β_1

Hipotesis:

H_0: $\beta_1 = 0$ (Tidak ada hubungan linear antara IPM (Y) dan Rataan Lama Sekolah)

H_1: $\beta_1 \neq 0$ (Ada hubungan linear antara IPM dan Rataan Lama Sekolah)

```{r}
cat("Nilai t pada b1 adalah", t_b1, "dengan nilai p sebesar", p_b1, "\n")
```
```
Nilai t pada b1 adalah 7.834462 dengan nilai p sebesar 1.558248e-08
```

$$t_{b_1} = \frac{b_1}{S_{b_1}} = \frac{0.036}{0.00426} = 7.834462$$
```

```{r}
t_table <- abs(qt(0.025, df = n-2))
t_table
```

```
[1] 2.048407
```

$$t_{tabel(0.025;28)} = 2.048$$

Nilai $|t_{b_0}| > t_{tabel}$ dan $|t_{b_1}| > t_{tabel}$ sehingga signifikan pada taraf nyata 5%. Hal ini berarti kedua parameter regresi menolah H_0 yang berarti nilai IPM saat Rataan Lama Sekolah nol tidak sama dengan nol dan ada hubungan linear antara Rataan Lama Sekolah dengan IPM.

7. Selang Kepercayaan Parameter

Selang kepercayaan β_0: $\widehat{\beta_0} \pm t_{\alpha/2,n-2} S_{\widehat{\beta_0}}$

```{r}
# Selang kepercayaan beta0
lower_b0 <- b0 - t_table * se_b0
upper_b0 <- b0 + t_table * se_b0
cat("Selang kepercayaan beta0: [", lower_b0, ", ", upper_b0, "]\n")
```

```
Selang kepercayaan beta0: [ 0.1475278 ,  0.4493215 ]
```

Selang bawah: $0.298 - (2.048)(0.07367) = 0.1475278$

Selang atas: $0.298 + (2.048)(0.07367) = 0.4493215$

Selang kepercayaan β_1: $\widehat{\beta_1} \pm t_{\alpha/2,n-2} S_{\widehat{\beta_1}}$

```{r}
# Selang kepercayaan beta1
lower_b1 <- b1 - t_table * se_b1
upper_b1 <- b1 + t_table * se_b1
cat("Selang kepercayaan beta1: [", lower_b1, ", ", upper_b1, "]\n")
```

```
Selang kepercayaan beta1: [ 0.02671919 ,  0.0456377 ]
```

Selang bawah: $0.036 - (2.048)(0.00462) = 0.02671919$

Selang atas: $0.036 + (2.048)(0.00462) = 0.0456377$

Sehingga dapat disimpulkan bahwa pada taraf signifikansi 5% selang kepercayaan pada parameter β_0 adalah [0.1475278, 0.4493215] dan untuk parameter β1 adalah [0.02671919, 0.0456377].

8. Selang Kepercayaan Bagi Nilai Rataan/Nilai Harapan Amatan

$$\hat{y}(x_i) \pm t_{\alpha/2,n-2} S_e \sqrt{\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}}$$

```{r}
amatan.diduga <- data.frame(X=10)
predict(model, amatan.diduga, interval = "confidence")
```

```
        fit       lwr       upr
1 0.6602091 0.6018964 0.7185217
```

x = 10

Selang bawah: $0.66 - (2.048)(0.0026)\left(\sqrt{\frac{1}{30} + \frac{10-15.82365997}{122.6}}\right) = 0.6018964$

Selang atas: $0.66 + (2.048)(0.0026)\left(\sqrt{\frac{1}{30} + \frac{10-15.82365997}{122.6}}\right) = 0.7185217$

Berdasarkan output sintaks di atas, diketahui bahwa dugaan rataan nilai *Y* ketika nilai x=10 adalah 0.66. Selain itu, diindikasikan juga bahwa dalam taraf kepercayaan 95%, diyakini bahwa nilai dugaan rataan *Y* ketika nilai x=10 berada dalam selang 0.6018964 hingga 0.7185217.

9. Selang Kepercayaan Bagi Individu Amatan

$$\hat{y}(x_i) \pm t_{\alpha/2,n-2} S_e \sqrt{1 + \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}\right)}$$

```{r}
amatan.diduga <- data.frame(X=10)
predict(model, amatan.diduga, interval = "prediction")
```

```
        fit      lwr       upr
1 0.6602091 0.540324 0.7800941
```

x = 10

Selang bawah: $0.66 - (2.048)(0.0026)\left(\sqrt{1+\frac{1}{30}+\frac{10-15.82365997}{122.6}}\right) = 0.540324$

Selang atas: $0.66 + (2.048)(0.0026)\left(\sqrt{1+\frac{1}{30}+\frac{10-15.82365997}{122.6}}\right) = 0.7800941$

Berdasarkan output sintaks dan nilai di atas, diketahui bahwa dugaan nilai individu Y ketika nilai x=10 adalah 0.66. Selain itu, diindikasikan juga bahwa dalam taraf kepercayaan 95%, diyakini bahwa nilai amatan individu Y ketika nilai x=10 berada dalam selang 0.540324 hingga 0.7800941.

10. Koefisien Determinasi

$$r = \frac{S_{XY}}{\sqrt{S_{XX} \times S_{YY}}} = \frac{4.436}{\sqrt{(122.624)(0.2337)}} = 0.8287$$

$$R^2 = r^2 = (0.8287)^2 = 0.6867$$

$$Adjusted\ R^2 = 1 - \frac{(1-R^2)(n-1)}{n-p-1} = 1 - \frac{(1-0.6867)}{n-1-1} = 0.6755382$$

- r: Koefisien korelasi
- R^2: Koefisien determinasi
- n: Jumlah sampel
- p: Jumlah variabel independen

```
### Koefisien Determinasi dan Penyesuaiannya
pada analisis regresi sederhana, koefisien determinasi yang digunakan adalah multiple R
Squared, sedangkan regresi linier berganda menggunakan adjusted R Squared yang disesuaikan
dengan banyak peubah
```{r}
r <- (sum(x*y)-sum(x)*sum(y)/n)/
sqrt((sum(x^2)-(sum(x)^2/n))*(sum(y^2)-(sum(y)^2/n)))
Koef_det <- r^2
cat("Nilai koefisien korelasi:", r, "\n")
```
```
Nilai koefisien korelasi: 0.8286897
```

```{r}
cat("Nilai koefisien determinasi:", Koef_det)
```
```
Nilai koefisien determinasi: 0.6867266
```

```{r}
Adj_R2 <- 1-((1-Koef_det)*(n-1)/(n-1-1))
Adj_R2
```
```
[1] 0.6755382
```

Nilai $R^2 = 0.686766$ menunjukkan bahwa 68,68% keragaman IPM dapat dijelaskan oleh variabel Rataan Lama Sekolah.

11. Kesimpulan

Berdasarkan analisis regresi linier sederhana terhadap 30 data Rataan Lama Sekolah dan IPM, dapat disimpulkan bahwa model $\hat{y} = 0.298 + 0.362x$ dinyatakan layak dan signifikan pada taraf nyata 5% karena nilai F-hitung (61,379) dan t-hitung keduanya melebihi nilai tabel kritisnya. Hasil ini menunjukkan adanya hubungan linear positif yang nyata, di mana setiap penambahan satu satuan rataan sekolah diprediksi meningkatkan IPM sebesar 0,036 unit dengan kekuatan hubungan sebesar 68,67% sebagaimana ditunjukkan oleh R^2.
```